

Análisis de sentimientos sobre reseñas de productos de belleza en Amazon utilizando vectorización TF-IDF

Leonardo García Muñoz

25 de Julio de 2026

1. Introducción

Una plataforma tan gigantesca como Amazon genera grandes volúmenes de datos, información, interacciones y como el giro del negocio lo necesita, también reseñas de usuarios. Mismas en las cuales se combina un texto libre con una calificación numérica en forma de estrellas. El texto de la reseña contiene información esencial sobre el porqué de esa opinión, por lo que resulta de interés preguntarse qué tanto coincide el sentimiento que se puede extraer del texto con la calificación que el usuario asignó. Con el siguiente análisis se busca comparar el sentimiento del texto contra la calificación numérica reportada en las reseñas.

2. Metodología

Para este análisis se utilizó el dataset público Amazon Reviews 2023 (McAuley Lab), específicamente se utilizó la categoría All Beauty, la cual incluye reseñas de usuarios, título y calificación de 1 a 5 estrellas. De 701,528 reseñas disponibles con texto, título y calificación no nulos, se tomó una muestra aleatoria de 5,000 reseñas para realizar el análisis.

En la etapa de preprocesamiento, el texto de cada reseña se convirtió a minúsculas y se eliminaron signos de puntuación. Posteriormente se aplicó tokenización con la librería nltk, se removieron las palabras vacías del idioma inglés y los tokens compuestos únicamente por números. Las reseñas que, tras la limpieza, quedaron sin ningún token útil fueron descartadas, quedando un total de 4,984 reseñas utilizables.

Con el texto ya preprocesado se entrenó un vectorizador TF-IDF, limitando el vocabulario a las 3,000 palabras más frecuentes y haciendo que cada término apareciera al menos en 2 reseñas distintas.

Para el análisis de sentimiento se utilizó AFINN el cual fue visto en clase, el cual asigna a un conjunto de

palabras en inglés un puntaje de polaridad entre -5 y 5. Cada token de cada reseña se cruzó contra este léxico y se sumaron los puntajes encontrados para obtener un puntaje de sentimiento por reseña. Aquellas sin ninguna palabra reconocida en el léxico se trataron como neutras (0). A partir de ese puntaje se clasificó cada reseña como positiva, negativa o neutra. Finalmente, se comparó el sentimiento estimado contra un "sentimiento real".

3. Resultados

3.1. Distribución de las calificaciones

En la siguiente gráfica se observa como la muestra de reseñas está fuertemente sesgada hacia calificaciones altas.




Figura 1: Distribución de calificaciones en reseñas.

3.2. Sentimiento detectado con AFINN

Al clasificar cada reseña según el signo del puntaje de sentimiento obtenido con AFINN, la mayoría de las reseñas fueron clasificadas como positivas. Esta distri-

bución es consistente con el sesgo hacia calificaciones altas observado en el grafico anterior.




Figura 2: Sentimiento detectado en las reseñas

3.3. Relación entre calificación y sentimiento del texto

El siguiente boxplot muestra una tendencia creciente clara, conforme aumenta la calificación en estrellas, también aumenta la mediana del puntaje de sentimiento del texto, y las reseñas de 1 y 2 estrellas concentran los puntajes de sentimiento más bajos. Pero también se observa bastante dispersión y valores atípicos dentro de cada grupo, lo que indica que la relación no es perfecta o regla, existen reseñas con calificación baja cuyo texto fue detectado como poco negativo o incluso positivo, y viceversa. Lo cual por ley de los grandes numeros podría hacer sentido.




Figura 3: Sentimiento detectado en las reseñas

3.4. Comparación directa

Con la siguiente tabla podemos apreciar la comparación de las estimaciones contra los sentimientos reales y analizar que tan preciso fue el reconocimiento de los sentimientos en los textos.

Cuadro 1: Tabla de confusión entre el sentimiento real y el sentimiento predicho a partir del texto.

Real \ Predicho	Negativo	Neutro	Positivo
Negativo	285	287	439
Neutro	55	82	235
Positivo	124	427	3,050

4. Conclusiones

El análisis mostró que el sentimiento del texto y la calificación numérica están relacionados, pero de forma moderada pues la correlación entre ambos fue de 0.419 y coincidieron en el 68.56 % de las reseñas. Esta relación es más confiable para reseñas positivas, ya que como vimos con anterioridad, AFINN las identifica bien, mientras que en las negativas falla con mucha mas frecuencia, probablemente porque las quejas sobre productos no siempre usan palabras claramente negativas, si no mas bien describen aspectos especificos del producto que fallo o un critica no tan grave como una critica a algun color a algun tono etc. Esto sugiere que AFINN por sí solo es útil pero limitado, sobre todo para detectar reseñas genuinamente negativas.