

Diseño de experimentos para clasificación de textos: comparación de modelos y sus hiperparámetros

Leonardo García Muñoz

1 de Agosto de 2026

1. Introducción

En el siguiente trabajo se diseñará un experimento que comparará modelos y sus hiperparámetros con relación a la clasificación de textos, utilizando el mismo conjunto de datos que se utilizó en clase: SMS Spam Collection Dataset, con 5,572 mensajes etiquetados.

2. Metodología

El texto se limpió con el mismo procedimiento que en clase (minúsculas, eliminación de caracteres no alfabéticos, eliminación de *stopwords*), y se dividió en 80 % entrenamiento / 20 % prueba para conservar la proporción ham/spam en ambos conjuntos.

2.1. Representaciones vectoriales

Se evaluaron las cuatro representaciones usadas en clase:

- **Conteo:** `CountVectorizer` sobre palabras.
- **TF-IDF palabras:** `TfidfVectorizer` con `analyzer='word'`.
- **TF-IDF n-gramas:** `TfidfVectorizer` con `ngram_range=(2, 3)`.
- **TF-IDF caracteres:** `TfidfVectorizer` con `analyzer='char'`.

Para las representaciones basadas en palabras y n-gramas se limitó el vocabulario a las 3,000 características más frecuentes (`max_features=3000`) (esto por capacidad de procesamiento de collab) la representación de caracteres no requirió este límite (solo 27 caracteres distintos tras la limpieza).

2.2. Modelos e hiperparámetros

Se compararon cuatro familias de modelos, cada una con una búsqueda de hiperparámetros por validación cruzada

Para cada una de las 4 representaciones vectoriales se entrenaron los 4 modelos, seleccionando en cada caso los hiperparámetros con mejor F1-macro promedio en validación cruzada sobre el conjunto de entrenamiento, y evaluando finalmente esa mejor configuración sobre el conjunto de prueba. En total se evaluaron 16 combinaciones de vectorización $\times$ modelo.

3. Resultados

La Tabla 1 muestra el ranking completo de las 16 combinaciones evaluadas, ordenadas por F1-macro en el conjunto de prueba.

Cuadro 1: Resultados de las 16 combinaciones vectorización $\times$ modelo, ordenadas por F1-macro (test)

Vectorización	Modelo	Accuracy	Precisión (spam)	Recall (spam)	F1-macro
Conteo	Reg. Logística	0.984	1.000	0.879	0.963
TF-IDF palabras	SVM lineal	0.982	0.978	0.886	0.960
Conteo	SVM lineal	0.982	1.000	0.866	0.959
TF-IDF palabras	Reg. Logística	0.980	0.985	0.866	0.955
Conteo	Naive Bayes	0.979	0.944	0.899	0.955
TF-IDF palabras	Naive Bayes	0.979	0.957	0.886	0.954
TF-IDF palabras	Random Forest	0.975	0.992	0.819	0.941
Conteo	Random Forest	0.973	1.000	0.799	0.936
TF-IDF n-gramas	Naive Bayes	0.967	0.952	0.792	0.923
TF-IDF n-gramas	SVM lineal	0.962	0.973	0.738	0.909
TF-IDF n-gramas	Reg. Logística	0.960	0.991	0.705	0.900
TF-IDF n-gramas	Random Forest	0.958	0.981	0.698	0.896
TF-IDF caracteres	Random Forest	0.954	0.980	0.671	0.886
TF-IDF caracteres	SVM lineal	0.925	0.810	0.570	0.813
TF-IDF caracteres	Reg. Logística	0.918	0.790	0.530	0.794
TF-IDF caracteres	Naive Bayes	0.866	0.000	0.000	0.464




Figura 1: F1-macro (test) por modelo y vectorización.

La mejor combinación global fue **conteo de palabras + regresión logística** ($C = 10$), con *accuracy* de 98.4 %, precisión perfecta (1.000) para la clase *spam* y recall de 0.879, resultando en un F1-macro de 0.963. Su matriz de confusión en el conjunto de prueba se muestra justo abajo.




Figura 2: Matriz de confusión de la mejor combinación (conteo + regresión logística) sobre el conjunto de prueba.

4. Conclusiones

Se buscaba responder el ¿qué combinación de técnicas detecta mejor los mensajes de spam? Cuando se representó cada mensaje simplemente contando qué palabras contiene, los cuatro modelos probados obtuvieron resultados muy buenos, arriba de 93 % de F1-macro. En cambio, cuando se representó el texto a nivel de caracteres individuales en vez de palabras, todos los modelos empeoraron, y en el peor de los casos el modelo simplemente dejó de detectar spam por completo, clasificando todo como si fuese un mensaje normal.

Esto tiene una explicación intuitiva: el spam se reconoce por palabras muy específicas (“gratis”, “gana”, “urgente”, números de teléfono, etc.), no por letras individuales que aparecen en el mensaje. Al fragmentar el texto en caracteres se pierde justo esa señal o ese tipo de bandera que hace al spam identificable.

La mejor combinación general fue la más simple de todas: contar palabras y usar regresión logística. Con esto se logró un 98.4 % de exactitud, y de los mensajes que el modelo marcó como spam, el 100 % realmente lo eran.

En resumen, este experimento confirma que mas complejidad no siempre significa mejores resultados, el modelo más simple y la representación más directa del texto superaron a alternativas más elaboradas como los n-gramas o un Random Forest, que además tardan mucho mas tiempo en entrenarse.