

Detección y análisis de masas circulares en imágenes de mamografías mediante algoritmos que no pertenecen al Deep Learning

Leonardo García Muñoz

2 de Agosto del 2026

1. Introducción

Las mamografías son un gran avance tecnologico para el estudio y prevencion de padecimientos en las mujeres, el problema existente sobre las mismas es la posible lentitud de deteccion temprana de algunos pacientes que en un largo plazo terminan desarrollando padecimientos en sus mamas.

Una de las soluciones mas interesantes es la utilizacion de las mamografías en investigaciones, modelos, artículos científicos donde se busca la manera mas eficiente de realizar detecciones tempranas de masas no normales en las mamas de las mujeres. Por lo que en este reporte analizaremos que tan viable es la detección de masas circulares (las cuales evidentemente no deberian de existir en las mamas al no ser elementos que sean parte del funcionamiento del cuerpo humano) mediante algoritmos que no convivan, o no sean parte de Redes Neuronales Convolucionales, pues se utilizaran algoritmos distintos, los cuales serian considerados mas rudimentarios o mas ortodoxos si de replicabilidad y automatizacion se habla.

2. Metodología

Para este análisis se utiliza el dataset público mini-MIAS (Mammographic Image Analysis Society), que contiene 322 mamografías en escala de grises, todo el dataset cuenta con metadata relevante. Cada imagen contiene anotaciones hechas por radiólogos: el tipo de tejido, si hay o no una anomalía, su severidad (benigna o maligna) y la ubicación exacta (centro y radio) de la masa encontrada.

De las 322 imágenes, se seleccionó únicamente el subconjunto de masas clasificadas como CIRC"(circunscritas), es decir, las que tienen una forma notoriamente redonda. Esto se hizo porque el método que se planeaba usar "Hough Circles", solo

tiene sentido aplicarlo sobre objetos que efectivamente sean circulares; masas con formas irregulares quedaron fuera del análisis por esa misma razón. Este filtro dejó 24 casos utilizables.




Figura 1: Muestra de las imágenes contenidas en el dataset.

Antes de aplicar la detección, se hizo una exploración general como la vista en clases previas, para entender mejor con qué se estaba trabajando: se revisaron los canales de color (encontrando que, al ser imágenes en escala de grises, los tres canales resultan practicamente idénticos), se calcularon histogramas de intensidad para ver el contraste visual, se probaron resoluciones mediante redimensión (no distinta compresión), y se detectaron puntos clave con el algoritmo ORB como referencia de qué tan "texturizadas" son estas imágenes.

Con esa base, se construyó el proceso de detección:

cada imagen se convirtió a escala de grises y se le aplicó un desenfoque gaussiano para suavizar el ruido y resaltar los bordes relevantes, haciendo o intentando que fuese mas sencilla la detección. Sobre esa versión suavizada se aplicó Hough Circles, que recorre la imagen buscando patrones circulares y regresa, para cada uno de los que encuentra, sus coordenadas de centro y su radio aproximado.

Los resultados obtenidos se compararon visualmente contra la anotación real del radiólogo (dibujando el círculo real en verde y el detectado en rojo sobre la misma imagen), y también de forma numérica: para cada caso se calculó la distancia entre el centro detectado y el centro real, y la diferencia entre el radio detectado y el radio real. Con estos valores se obtuvo una tasa de detección general y un error promedio, lo que permitió medir de forma objetiva qué tan confiable es el método, en lugar de basarse solo en la inspección visual de unos cuantos ejemplos.

3. Resultados

Recordando que se consideraron solo 24 imágenes las cuales tenían una masa clasificada como circular (CIRC), que fue el subconjunto usado para estas pruebas.

Tenemos las pruebas principales vistas en clase:

3.1. Visualización de canales individuales




Figura 2: Imagen de ejemplo para aplicar la visualización de canales

Observamos como se menciona en la Metodología, al ser imágenes que se encuentran en escalas de grises, los canales no aplican ningún cambio en la imagen. Se necesitarían imágenes con mezclas de colores para poder ver diferencias al separar los canales.

3.2. Histogramas de intensidades




Figura 3: Imagen de ejemplo para imprimir el Histograma de intensidades




Figura 4: Otra imagen de ejemplo para imprimir el Histograma de intensidades

Considerando que el histograma te dice como se reparten las escalas de gris en la imagen (0 = negro, 255 = blanco, el rango entre esos valores son escalas de gris)

Tenemos que la imagen tiene muchos pixeles concentrados en negro y blanco principalmente, con muy pocos pixeles tocando diferentes escalas de grises, vemos una intensidad concentrada en negro (un factor esperable observando la imagen de ejemplo). Pero bajo el entendimiento de que el resto de imágenes del subconjunto tienen la misma composición, se podría decir que las imágenes tienen un mismo tipo de comportamiento en cuanto a intensidad, y por lo tanto Hough Circles se comportaría de igual manera para todas las imágenes, pero también podría dificultarse la detección de patrones circulares, debido al poco contraste de colores, podría confundir figuras que se asemejen a figuras circulares.

3.3. Redimensión del subconjunto




Figura 5: Imagen con los ejemplos del redimensionamiento

De lo mas interesante en el experimento es apreciar que, apesar de la redimension de las imagenes del subconjunto. Los detalles de las mamografías no pierden mucho detalle, cualidad la cual podria ser beneficiosa si se hablara de aplicarlo en imagenes con dimensiones mas pequeñas. Este factor podría tener relación probable con la composicion de las imagenes, la cual se encuentra en puras escalas de grises.

El unico cambio notorio, es que los bordes de los detalles de las mamas pierde calidad, pero solo pasan de estar bien definidos a con bordes irregulares.

3.4. Puntos clave de la imagen




Figura 6: Imagen aplicando ORB para detectar puntos clave en las mamografías

Tenemos que tomar en cuenta que ORB detecta esquinas y zonas donde hay un fuerte contraste, por lo que considerando lo escrito en la seccion anterior, sabremos que sera dificil que ORB detecte de una manera precisa zonas de contraste, pues en la escala de grises donde la imagen se encuentra no son tan precisos los contrastes.

Este contraste bajo en las imagenes explican porque ORB detecta de manera muy irregular puntos claves, en unas de las imagenes de ejemplo si detecta puntos clave justo en donde existen masas mamarias que evidentemente no son normales, mientras que en otras imagenes detectan puntos clave fuera de la mama analizada, lo cual nos indica que estos metodos mas rudimentarios (algoritmos de CV) son menos efectivos en datasets con características similares (y evidentemente, sin un preprocesamiento adicional o mas detallado; como recortar la región del seno antes de analizar, aplicar un contraste de algun color en especifico, entre otros detalles que podrian ayudar a los resultados).

3.5. Detección de patrones con HoughCircles




Figura 7: Imagen aplicando HoughCircles en las mamografías

En un primer vistazo, el algoritmo de Hough encontró algún círculo en el 95.8 % de las imágenes. A primera vista suena como un resultado muy bueno, pero ese número solo dice que el algoritmo detectó algo circular en la imagen, pero no necesariamente la masa correcta, o en el lugar adecuado. Al comparar la ubicación de lo detectado contra la ubicación real anotada por el radiólogo, el panorama cambia bastante: el error promedio entre el centro detectado y el centro real fue de 347.8 píxeles (mediana de 289.2 px), y el error promedio en el tamaño del radio fue de 71.5 píxeles. Son errores grandes si se toma en cuenta que muchas de las masas reales miden entre 20 y 90 píxeles de radio.

Para tener una medida más justa de qué tan bien funcionó realmente el método, se revisó cuántos casos tuvieron un error de centro menor o igual al tamaño real de la masa (es decir, que el círculo detectado realmente cayera sobre o cerca del tumor, y no en cualquier otra parte de la imagen). Bajo ese criterio, solo 4 de los 24 casos (alrededor del 17 %) fueron detecciones verdaderamente acertadas. El resto de las "detecciones" correspondían a otros elementos circulares de la imagen, que muy probablemente el contorno del propio seno u otros elementos en la imagen que fueron de alto contraste, ocasionaron que el algoritmo confundiera esos elementos con la masa buscada.




Figura 8: Imagen aplicando HoughCircles en las mamografías

Esto también se ve reflejado en la distribución del error, pues en lugar de tener un solo grupo de casos con error bajo, los resultados se agrupan en dos bloques (como se aprecia en el histograma) uno con errores "pequeños" (detecciones que sí acertaron o se acercaron lo suficiente) y otro con errores muy grandes (casos donde el algoritmo se equivocó de objeto por completo), sin casos intermedios. Al comparar el error contra el tamaño real de cada masa tampoco se encontró un patrón claro: masas grandes y chicas tuvieron tanto buenos como malos resultados, lo que sugiere que el tamaño no es el factor que determina si Hough acierta o no.

4. Conclusiones

Con el experimento realizado, vemos que los algoritmos empleados no son tan precisos o efectivos para dataset con tantas peculiaridades como el utilizado, por lo que este tipo de métodos de visión por computadora, son mucho más débiles respecto a algoritmos de Deep Learning, que cuentan con uno de los factores que más marcan la diferencia, un entrenamiento respecto a las imágenes introducidas.

Pero podemos concluir que el experimento nos dio una conclusión que cual metodología es más efectiva, pero no nos dio conclusiones respecto a los tipos de masas encontradas respecto a las diferentes mamografías realizadas. Por lo que el experimento no terminó siendo tan concluyente como se buscaba, pero podría refinarse incluso con los algoritmos utilizados. Mediante un preprocesamiento lo suficientemente bueno para evitar los errores que se generaron.