

Procesamiento y clasificación de audios en el reconocimiento de dígitos hablados

Leonardo García Muñoz

2 de Agosto del 2026

1. Introducción y contexto de los datos

Este reporte documenta la implementación de un pipeline de procesamiento y clasificación de señales de audio reales, integrando las técnicas revisadas en clase, y utilizando el Free Spoken Digit Dataset (FSDD), un dataset público de voz humana real que contiene grabaciones de 6 personas distintas pronunciando los dígitos del 0 al 9 en inglés, 50 repeticiones por dígito y por persona (3000 archivos `.wav` en total).

2. Metodología

2.1 Exploración y visualización

Se cargan y visualizan ejemplos reales de distintos dígitos (mismo hablante, para comparar de forma justa) en las cuatro representaciones vistas en clase: forma de onda, espectrograma, MFCC y descomposición wavelet.

A diferencia de señales sintéticas puras, la voz humana tiene energía distribuida en varios niveles de la DWT simultáneamente (por la mezcla de armónicos y formantes de cada fonema), y la forma del espectrograma de cada dígito refleja su composición fonética (dígitos con sonidos sibilantes muestran más energía en frecuencias altas y más dispersión temporal que dígitos con vocales sostenidas).




Figura 1: Forma de onda de cada dígito (0–9), mismo hablante (jackson).




Figura 2: Espectrogramas (STFT, escala log de frecuencia) por dígito.




Figura 3: Coeficientes MFCC (13 coeficientes) por dígito.




Figura 4: Energía relativa por nivel de la descomposición DWT (db4, 4 niveles) por dígito.

2.2 Extracción de características

Cada audio se reduce a un vector de 37 características de tamaño fijo: media y desviación estándar de 13 MFCC a lo largo del tiempo (26 valores), 6 estadísticos agregados (centroide espectral, ancho de banda, tasa de cruces por cero, *rolloff*, *flatness* y duración del audio) y la energía relativa por nivel de una DWT de 4 niveles).

2.3 Clasificación de dígitos

El conjunto de 3000 ejemplos se dividió de forma estratificada en 80 % entrenamiento (2400 audios) y 20 % prueba (600 audios). Se entrenaron y compararon dos clasificadores: **Random Forest** (300 árboles) y **SVM** con kernel RBF ($C = 10$).

2.4 Análisis complementario con DTW sobre coeficientes wavelet

Para investigar los errores de clasificación, se identificó el par de dígitos con más confusiones en la matriz del modelo SVM, y se calculó la distancia DTW directamente sobre el coeficiente de detalle de mayor resolución (D1) de la DWT, comparando pares de audios del mismo dígito contra pares de los dos dígitos confundidos, usando 8 ejemplos de cada uno.

3. Resultados

3.1 Desempeño de los clasificadores

Modelo	Accuracy global	Par más confundido
Random Forest	0.973	6 / 8
SVM (RBF)	0.988	6 / 8

Cuadro 1: Accuracy global sobre el test set (600 audios, 60 por dígito).

Con voz real y un vocabulario cerrado de 10 dígitos, ambos modelos alcanzan un desempeño muy alto (>97 %). Los pocos errores que aparecen se concentran en el par 6/8 ("*six*" / "*eight*"), fonéticamente parecidos en inglés no en pares arbitrarios: el clasificador se equivoca de forma razonable, en los casos donde el sonido real es más confundible.

3.2 Distancia DTW sobre coeficientes wavelet: dígitos 6 y 8

Distancia DTW promedio intra-dígito: **15.87** (desv. est. 9.95). Distancia DTW promedio inter-dígito (6 vs. 8): **15.50** (desv. est. 10.28).




Figura 5: Matrices de confusión sobre el conjunto de prueba (600 audios) para Random Forest y SVM-RBF.




Figura 6: Distancias DTW intra-dígito vs. inter-dígito (6 vs. 8) sobre el coeficiente de detalle D1 de la DWT.

4. Conclusiones

Concluyendo despues de que se implementó un pipeline completo de procesamiento (MFCC, espectrograma, DWT) y clasificación (Random Forest, SVM) sobre un dataset **real** de voz humana: el Free Spoken Digit Dataset (3000 grabaciones, 6 hablantes, dígitos 0–9). Ambos clasificadores alcanzan una accuracy superior al 97% en la tarea de reconocer el dígito pronunciado (Random Forest 0.973, SVM-RBF 0.988).

Los errores de clasificación no son aleatorios: se concentran en el par 6/8, los cuales en ingles podrian generar confusiones en el algoritmo. El análisis de distancia DTW sobre coeficientes wavelet confirmó que esta confusión refleja una similitud acústica real y no una limitación.

Las mismas características usadas para identificar el dígito permiten también identificar al hablante con alta precisión (98.8%), evidenciando que el MFCC mezcla información fonética y de timbre.